

Matrix集群操作系统

百度-INF-吕斯哲



About

部门

- 基础架构部
- 大规模分布式系统

团队

- COS: Cluster Operating System
- Matrix/Normandy

- 吕斯哲
 - 阅读、慢跑、徒步



招聘: inf-jobs@baidu.com

演讲内容

Matrix

- 背景
- 定位

宏观结构

- 分层结构
- 关键概念

容器与混布

- 应用部署
- 隔离、避让
- 调度、超发

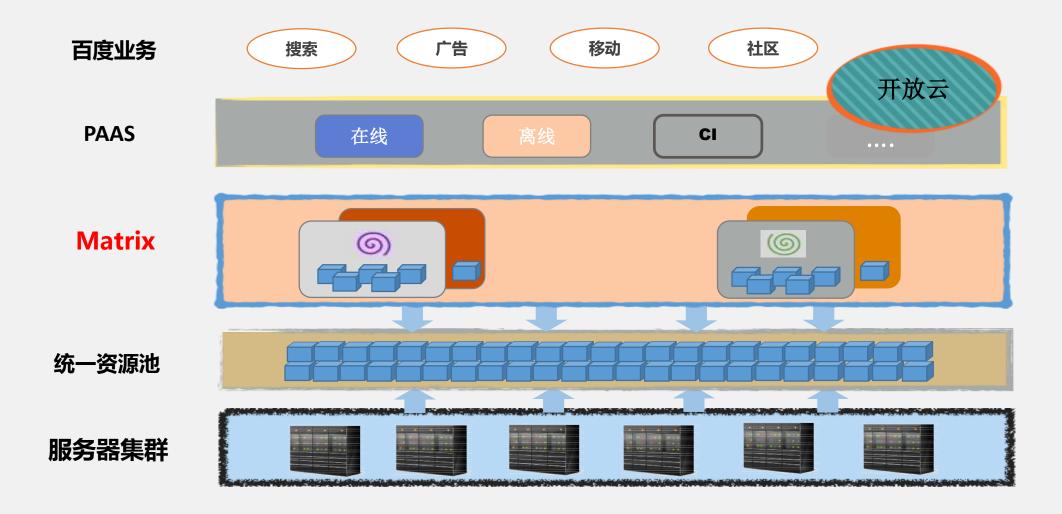
工程实施

- 系统工程
- 推进思路

Matrix是什么?



Matrix



历史

提升资源利用率

- CPU利用率
- 资源交付与流转效率

抽象资源操作接口

- PaaS、运维平台
- DevOps/CI/CD

Matrix

- 2012年启动
- 获百度最高奖

现状

规模

全集群:几十万台

单集群:几万台

容器数:几千万个

业务

almost all

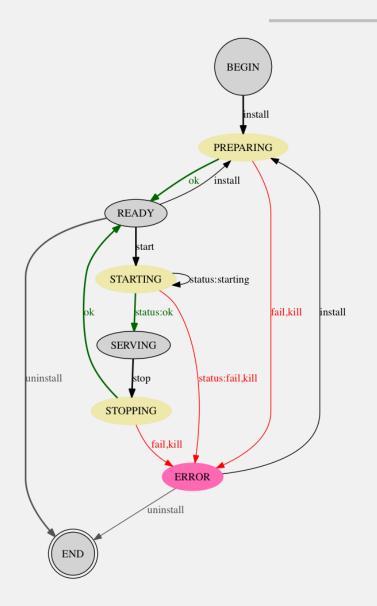
在线&离线

虚拟化战略

Matrix分层架构



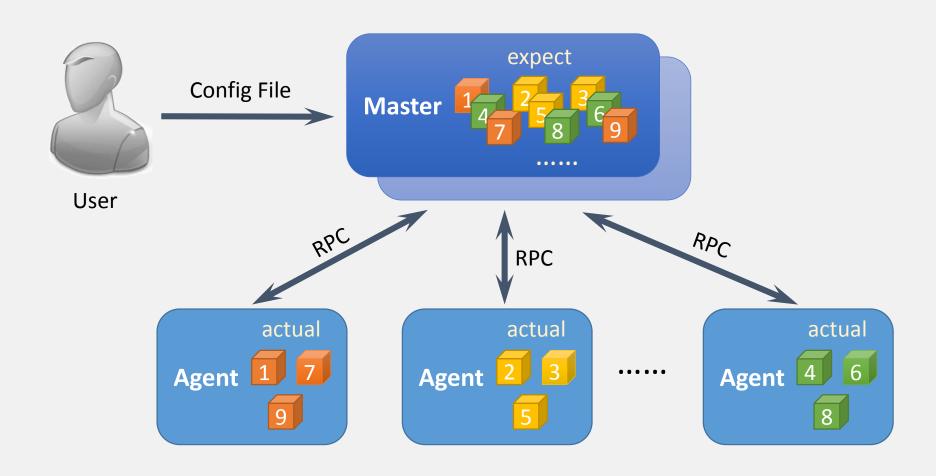
原理: 状态机设计



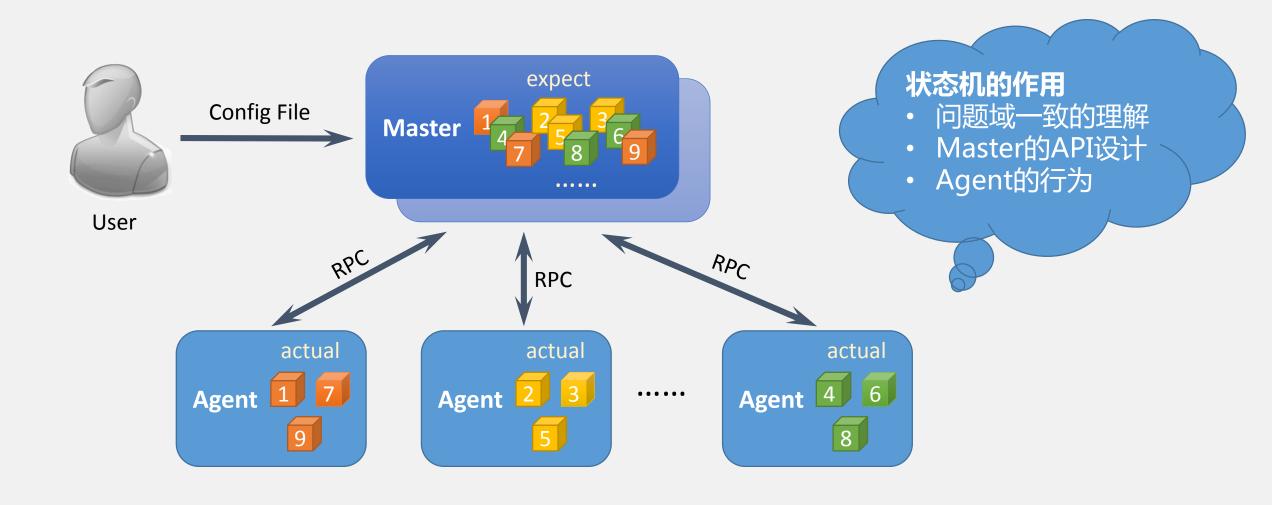
状态转移表

expect action	-	READY	SERVING
-	-	install	install
READY	uninstall	-	start
SERVING	stop	stop	-

原理: 状态机设计



原理: 状态机设计



哪些对象?

Host

- 机器流转
- 自动维修
- 环境一致"

机器管理 Ultron/Bios

Container

- 资源的集合
- 隔离技术的载体
- 资源调音始单点

Matrix-RM

Instance

- 资源的使用
- "进程"
- 应用部置

Matrix-IM

Service/Server

- 常驻"进程"
- 在线服务**

Solaria

Job/Command

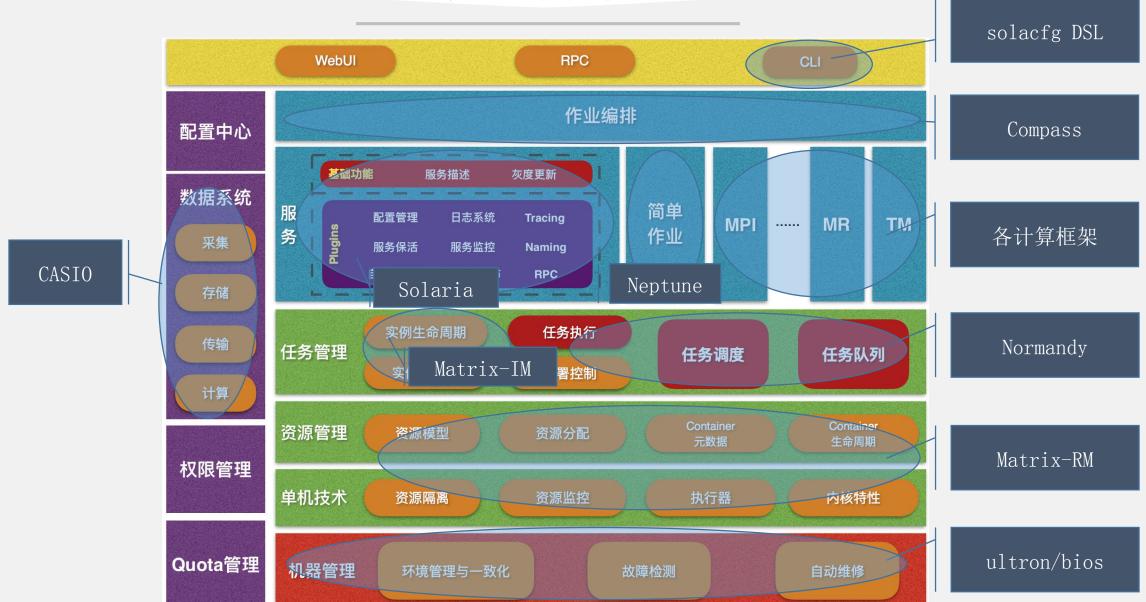
- 自结束"进程"
- 离线作业类

Solaria/Neptune

分层结构



分层结构



分层结构



- 分配资源:Container

buf = malloc(...)

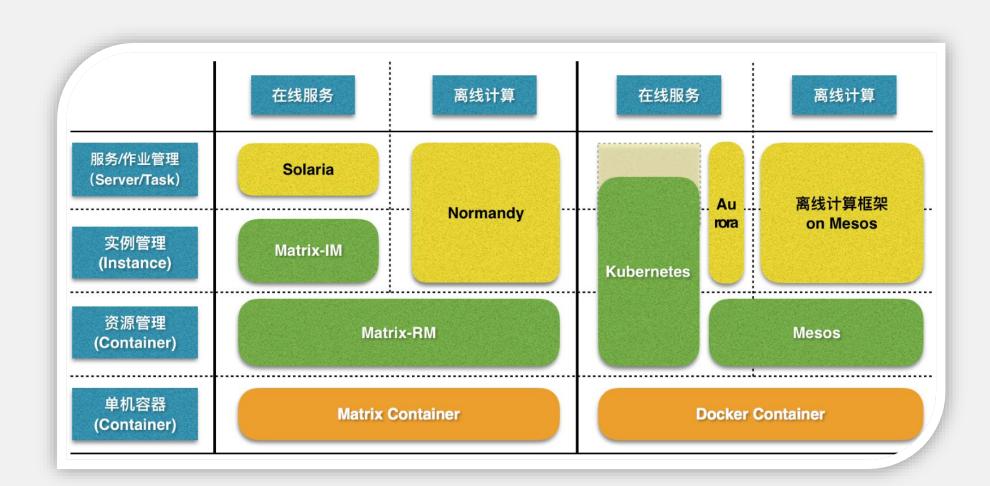
- 实例部署:Instance

instance = new (buf) CTOR(package)

- 模型分化
 - long-running: service/server
 - routine: job/command

server = (Server) instance
server.start()

社区对比

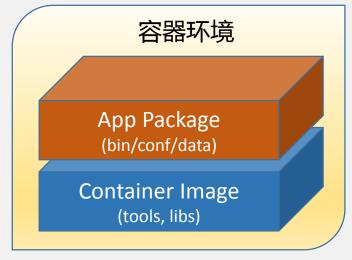


容器与混布



应用部署

- **Docker**: Container & Image
- Matrix :
 - ➤ 保留Matrix-Container
 - ✓ 保留自研混布、调度技术
 - ✓ 内部生态对接:可继续大规模部署
 - ➤ 支持Docker-Image部署
 - ✓ 两层结构:应用+容器
 - ✓ 现有部署系统兼容
 - ✓ 工具链升级: gcc, java, tomcat etc.



双层结构

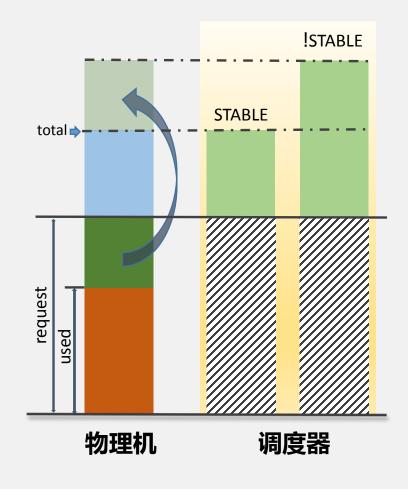
优先级与超发

优先级

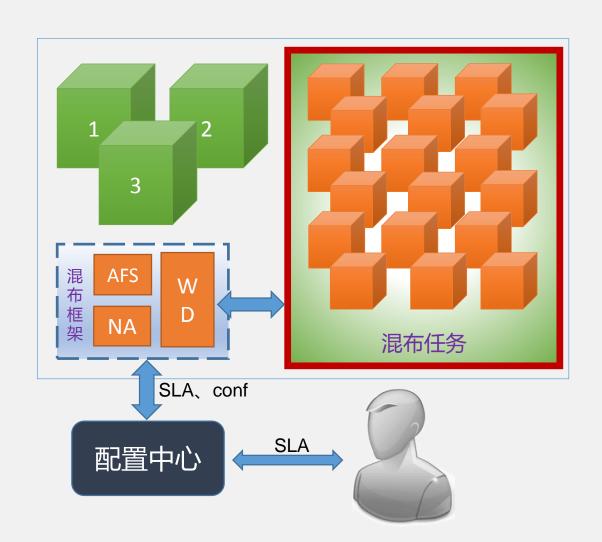
- STABLE > NORMAL > BESTEFFORT
- 单机:可否抢占
- 集群:是否有Quota

超发

- 用户行为: request used > 0
- 超发: total' = total + sum(request used)
- 约束: sum(STABLE) < total



隔离与避让



混布框架

• 存储: AFS(hdfs)

• 计算: Normandy-Agent

· 策略:watchdog

混布策略

• 确保非混布任务资源质量

• 本地监控: SLA、策略配置

· 本地即时处理:压缩 or kill

用户运营

• 签订SLA

· 资源结算模式调整(ing)

集群混布

离线间

- 跨计算模型
- 计算模型适配
- 集中调度
- 兼容YARN
- 2014 2015

在离线间

- 跨业务
- 离线数据
- 业务SLA保证
- 2015 Now

无差别

- 优美
- 调度策略优化
- 背包问题
- next...

大规模推广



为什么自研?

- 启动时间:2012年
- 重心:集群资源管理 vs 运维效率提升
- 降低业务接入成本:
 - ▶ 适配、脏逻辑
 - 内部生态对接: 机器维修、预结算、众多系统
 - ▶ 目标:扩大覆盖规模、业务多样性
- 紧盯社区:拆解替换、降低维护成本、反馈

推进过程

- Matrix-1.0
- 运维系统升级
- FAILED

2012H1

2012H2~2014H1

- Matrix-2.0
- Normandy立项
- 推广、稳定期
- 大搜、社区、商搜

- Matrix-3.0
- Normandy推广
- 大规模混布
- 覆盖率>50%

2014H2~2015H1

2015H2~Now

- PaaS组件建设
- Solaria
- 预结算、权限
- 系统整合



THANKS!

